

UNIVERSIDAD DEL VALLE DE GUATEMALA

Inteligencia Artificial – Sección 10

Ing. Luis Alberto Suriano



Proyecto Final – Sistema de Recomendación Musical

Osman Emanuel de León García – 23428

Guatemala, 24 de mayo de 2026

Proyecto – Sistema de Redes Bayesianas

Descripcion del problema

El descubrimiento musical personalizado representa uno de los desafíos más relevantes en la industria del entretenimiento digital. Plataformas como Spotify, Apple Music o Last.fm han logrado sistemas de recomendación sofisticados, pero estos dependen en su mayoría de grandes volúmenes de datos de comportamiento colectivo (filtrado colaborativo) y no modelan de forma explícita las dependencias probabilísticas entre las características intrínsecas de la música y las preferencias individuales del usuario.

El problema central que aborda este proyecto es: dado un perfil de preferencias musicales de un usuario (géneros favoritos y canciones de ejemplo que le gustan), ¿cómo inferir canciones que probablemente le gusten, basándose en las características de audio de la música y no únicamente en el comportamiento de otros usuarios?

Este problema tiene aplicación directa en:

- Sistemas de recomendación en plataformas de streaming musical
- Curaduría automática de playlists personalizadas
- Descubrimiento de música nueva fuera de las burbujas de filtro algorítmico
- Análisis del perfil musical de usuarios para marketing y producción

Análisis


Se utilizó el Spotify Tracks Dataset disponible públicamente en Kaggle, que contiene aproximadamente 114,000 canciones distribuidas en 114 géneros musicales, con 1,000 canciones por género (dataset perfectamente balanceado). Cada canción incluye las siguientes características de audio extraídas mediante la API de Spotify:



Feature	Rango	Descripción
danceability	0.0 – 1.0	Qué tanailable es la canción según tempo, ritmo y beat
energy	0.0 – 1.0	Intensidad y actividad perceptual de la pista
valence	0.0 – 1.0	Positividad musical (alto = alegre, bajo = triste)
acousticness	0.0 – 1.0	Probabilidad de que la pista sea acústica
tempo	BPM	Pulsos por minuto estimados
popularity	0 – 100	Popularidad calculada por Spotify
speechiness	0.0 – 1.0	Presencia de palabras habladas en la pista
instrumentalness	0.0 – 1.0	Predicción de si la pista no contiene voces

Para este proyecto se seleccionaron 10 géneros representativos que cubren distintos espectros musicales: reggaeton, latin, pop, rock, hip-hop, r-n-b, electronic, jazz, classical y metal.

Observaciones del EDA



Propuesta de Solucion

Se propone un sistema de recomendación musical híbrido que combina dos enfoques complementarios de Inteligencia Artificial:

Clasificación supervisada (Machine Learning)

Se entrenan tres modelos de clasificación para predecir el género musical de una canción dado su perfil de features de audio: K-Nearest Neighbors (KNN), Árbol de Decisión y Support Vector Machine (SVM). Estos modelos permiten comprender qué características son más discriminativas entre géneros y proveen una baseline de desempeño.

Inferencia probabilística (Red Bayesiana)

Se construye una Red Bayesiana Discreta que modela las dependencias probabilísticas entre el género musical, las características de audio discretizadas (energy, danceability, valence, acousticness) y la popularidad. La red permite responder queries del tipo: dado que el usuario prefiere reggaeton con alta danceability y energy alta, ¿cuál es la probabilidad de que una canción candidata sea popular?

Sistema de recomendación final

Se implementa un sistema interactivo (con widgets en Jupyter) donde el usuario selecciona géneros favoritos y canciones de ejemplo. El sistema extrae el perfil de audio del usuario, filtra candidatos compatibles, les asigna un score bayesiano mediante inferencia en la Red Bayesiana, y retorna un ranking de recomendaciones con visualizaciones comparativas.

Descripción de Solución

Preprocesamiento

Se aplicaron dos estrategias de preprocesamiento según el modelo destino:

- Para los modelos ML: normalización con StandardScaler para que KNN y SVM no sean sensibles a la diferencia de escala entre features como tempo (0-250 BPM) y danceability (0-1).
- Para la Red Bayesiana: discretización de variables continuas en tres niveles (bajo/medio/alto) usando quantiles para respetar la distribución real de los datos. La popularidad se discretizó con umbrales fijos: bajo (0-30), medio (30-60), alto (60-100).

Modelos de Machine Learning

Los tres clasificadores se entrenaron con un split 80/20 estratificado por género:

- KNN: se buscó el K óptimo mediante cross-validation de 5 folds en el rango K=1 a K=20.
- Árbol de Decisión: se buscó la profundidad máxima óptima (rango 3-20) mediante cross-validation, evaluando también importancia de features.
- SVM: se usó kernel RBF con C=1.0 y gamma='scale'.

Red Bayesiana

La estructura de la red se definió basándose en conocimiento del dominio musical y los patrones observados en el EDA:

Nodo padre	Nodo hijo	Justificación
genre	energy_d	El género determina el perfil de energía
genre	danceability_d	El género determina la bailabilidad
genre	valence_d	El género determina la valencia emocional
genre	acousticness_d	El género determina el nivel acústico
energy_d	popularity_d	La energía influye en la popularidad
danceability_d	popularity_d	La bailabilidad influye en la popularidad
valence_d	popularity_d	La positividad influye en la popularidad

Las tablas de probabilidad condicional (CPDs) se estimaron con Maximum Likelihood Estimation sobre el dataset de entrenamiento. La inferencia se realiza mediante Variable Elimination.

Demo Interactivo

Se implementó una interfaz interactiva con ipywidgets directamente en el Jupyter Notebook que guía al usuario en tres pasos:

- Paso 1: Selección de géneros favoritos mediante un selector múltiple.
- Paso 2: Selección de canciones de ejemplo de esos géneros (máximo 5).
- Paso 3: El sistema detecta el perfil musical del usuario, aplica inferencia bayesiana sobre los candidatos y presenta un ranking de recomendaciones con tabla y visualizaciones comparativas.

Herramientas Utilizadas

Herramienta	Versión	Uso en el proyecto
Python	3.10+	Lenguaje principal de implementación
pandas / numpy	2.x	Manejo y transformación del dataset
scikit-learn	1.x	KNN, SVM, Decision Tree, métricas, escalado
pgmpy	0.1.x	Red Bayesiana discreta, MLE, Variable Elimination
matplotlib / seaborn	3.x	Visualizaciones del EDA y resultados
ipywidgets	8.x	Interfaz interactiva en Jupyter
Jupyter Notebook	7.x	Entorno de desarrollo y presentación

Uso de Inteligencia Artificial Generativa


Durante el desarrollo del proyecto se utilizó Claude (Anthropic) como herramienta de apoyo para los siguientes aspectos:

- Diseño de la estructura de la Red Bayesiana y justificación de las dependencias entre nodos.
- Depuración de errores en la integración con pgmpy (migración de BayesianNetwork a DiscreteBayesianNetwork).
- Implementación del sistema de widgets interactivos con ipywidgets.
- Revisión de la estructura del documento final.



En todos los casos, el output generado fue revisado. El uso de IA se limitó a apoyo técnico y nunca a la generación directa de resultados o conclusiones.

Resultados

Desempeño de Modelos ML



Modelo	Accuracy	F1 Macro	Mejor clase	Peor clase
KNN (K óptimo)	~39%	~0.38	classical	r-n-b
Árbol de Decisión	~45%	~0.44	classical	hip-hop
SVM (RBF)	~25%	~0.24	metal	r-n-b





Desempeño de la Red Bayesiana

La Red Bayesiana se evaluó en su capacidad de predecir correctamente la categoría de popularidad (bajo/medio/alto) dado el perfil completo de una canción. Se evaluó sobre una muestra de 500 canciones del dataset con el modo máximo de la distribución posterior como predicción.

Accuracy en predicción de popularidad: ~45-50%. Este resultado es coherente con el hecho de que las correlaciones individuales con popularidad son bajas — la popularidad en Spotify depende de factores externos al audio (marketing, viralidad, contexto cultural) que no están capturados en el dataset.

Análisis de Sensibilidad



Conclusiones

- La combinación de modelos de Machine Learning supervisado y una Red Bayesiana permite abordar el problema de recomendación musical desde dos perspectivas complementarias: los clasificadores identifican patrones discriminativos entre géneros, mientras que la Red Bayesiana captura dependencias probabilísticas conjuntas que ningún modelo individual puede modelar.
- El Árbol de Decisión fue el mejor clasificador de géneros, con ~45% de accuracy sobre 10 géneros — un desempeño razonable considerando que varios géneros (latin, reggaeton, hip-hop, r-n-b) comparten un espacio de features similar.
- La Red Bayesiana demostró ser una herramienta poderosa para el razonamiento bajo incertidumbre: permite hacer inferencia con evidencia parcial y cuantifica la incertidumbre en las predicciones, lo que no es posible con los clasificadores supervisados.
- El análisis de sensibilidad reveló que danceability es el feature más influyente en la popularidad para el género pop, mientras que valence tiene menor peso individual, un hallazgo no intuitivo que solo emerge al analizar la distribución conjunta de variables.
- El sistema interactivo (ipywidgets) permite una demostración natural del flujo de recomendación y es adecuado para presentación en clase sin requerir infraestructura adicional.
- Como trabajo futuro, se podría integrar la API real de Spotify para obtener el historial de escucha del usuario, explorar Gaussian Bayesian Networks para mantener variables continuas, y comparar con modelos de filtrado colaborativo.

Link del Repositorio

https://github.com/Emadlgg/Proyecto_Final_IA.git

Enlace Presentación: <https://canva.link/f4vgmjrtv6xe396>

Bibliografía

- Russell, S. J., & Norvig, P. (2020). Artificial Intelligence: A Modern Approach (4th ed.). Pearson.
- Rogers, S., & Girolami, M. (2016). A First Course in Machine Learning (2nd ed.). CRC Press.
- Ng, A. (2018). Machine Learning Yearning. Deeplearning.ai.
- Ankan, A., & Panda, A. (2015). pgmpy: Probabilistic Graphical Models using Python. Proceedings of the 14th Python in Science Conference.
- Maharshi Pandya. (2022). Spotify Tracks Dataset. Kaggle.
<https://www.kaggle.com/datasets/maharshipandya/-spotify-tracks-dataset>
- Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.